

INFORME DE TALLER 02

Clasificación de Churn: Regresión Logística, SMOTE, Pesos de Clase y PCA

Maestría en Ciencia de Datos | Machine Learning (Semana 1)

Autores: Nancy Altamirano y Kevin Viteri

Resumen Ejecutivo del Experimento

Modelo / Experimento	Estrategia de Balanceo / Reducción	Hiperparámetro Lambda (C)	Test Accuracy	Test Recall	Resultado Clave
Actividad 1	Undersampling (Submuestreo aleatorio)	$\lambda = 10000$ (C = 0.0001)	73.17%	79.68%	Buen equilibrio general; descarta el 60% de clientes activos.
Actividad 2	SMOTE + Pesos de Clase (Class Weights)	$\lambda = 1$ (C = 1.0)	67.00%	87.97%	Incremento del recall en +8.29%; no pierde datos reales.
Actividad 3	SMOTE + Pesos de Clase + PCA (95%)	$\lambda = 1$ (C = 1.0)	64.23%	91.44%	Mayor recall del estudio (91.44%); reducción de 861 a 114 features.

Checklist de Entrega

Item del Laboratorio	Estado de Cumplimiento	Evidencia en el Entregable
Código ejecuta sin errores (reproducible)	SÍ	Notebook totalmente ejecutado en-place sin tracebacks.
Actividad 1 completa: Búsqueda en Rejilla de Lambda y Curva de Complejidad	SÍ	Búsqueda con CV=5, gráfica logarítmica generada y guardada.
Actividad 2 completa: Pipeline con SMOTE y Pesos de Clase en Dataset Completo	SÍ	Implementación con imblearn Pipeline, matrices de confusión generadas.
Actividad 3 completa: Pipeline con Polynomials + PCA (95%) + SMOTE + Pesos	SÍ	Modelado secuencial, curvas ROC comparativas y barras finales graficadas.
Conclusiones y Recomendaciones de Negocio detalladas	SÍ	Sustento económico del recall frente a exactitud y tabla comparativa.
Generación física de gráficos y embebido en Markdown/PDF	SÍ	5 archivos PNG guardados y renderizados dinámicamente en el informe.

1. Fundamento Teórico del Curso

Fundamento teórico: regularization-13-oct-2024.pdf, modelselection24nov2025.pdf, reglinmultivariate-13-oct-2024.pdf

1.1 Modelo de Regresión Logística y la Clasificación Binaria

El modelo de regresión logística se utiliza para predecir la probabilidad de que una variable objetivo binaria Y pertenezca a la clase positiva (en este caso, Churn = 1). La hipótesis utiliza la función sigmoide para mapear la salida lineal de los coeficientes a un rango de $[0, 1]$:

$$h_{\theta}(x) = g(\theta^T * x) = 1 / (1 + e^{-(\theta^T * x)})$$

La función de costo que se minimiza mediante optimización (como liblinear o lbfgs) es la entropía cruzada binaria (Log-Loss):

$$J(\theta) = - (1/m) * \sum_{i=1}^m [y^{(i)} * \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) * \log(1 - h_{\theta}(x^{(i)}))]$$

1.2 Regularización L2 (Ridge) y el Hiperparámetro Lambda

Para contrarrestar el sobreajuste provocado por expansiones de alta dimensionalidad (como PolynomialFeatures), se añade un término de penalización L2 que limita la magnitud de los pesos del modelo:

$$J_{\text{reg}}(\theta) = J(\theta) + \lambda * \sum_{j=1}^n (\theta_j^2)$$

En la implementación de scikit-learn (`LogisticRegression`), se utiliza el parámetro C , que corresponde a la inversa de la regularización λ ($C = 1 / \lambda$). Un valor muy bajo de C equivale a un λ extremadamente alto, forzando una fuerte penalización y disminuyendo la varianza del modelo a costa de incrementar el sesgo.

1.3 Métricas en Datos Desbalanceados: ¿Por qué priorizar Recall?

En problemas comerciales de abandono de clientes (churn), el conjunto de datos suele estar altamente desbalanceado (en Telco Churn, la proporción es de 3 a 1). En este contexto, la métrica **Accuracy (Exactitud)** resulta engañosa: un modelo ingenuo que clasifique a todos los clientes como "No Churn" obtendría un 73.4% de exactitud, pero fallaría en detectar el 100% de los desertores.

Por ello, se prioriza el **Recall (Sensibilidad)**, definido como:

$$\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$$

Un Falso Negativo (FN) representa a un cliente que va a cancelar su servicio pero que el modelo etiqueta como activo, lo que impide que la empresa tome medidas de retención y genera una pérdida económica directa. Minimizar los Falsos Negativos maximiza el Recall.

1.4 Técnicas de Balanceo: Undersampling vs. SMOTE

- **Submuestreo (Undersampling):** Reduce aleatoriamente las muestras de la clase mayoritaria (No Churn) para igualarla con la minoritaria. Su ventaja es la reducción del tiempo de cómputo, pero su gran desventaja es la pérdida de información valiosa (cerca del 60% de los datos reales de clientes activos).
- **SMOTE (Synthetic Minority Over-sampling Technique):** Genera sintéticamente nuevos puntos de la clase minoritaria mediante interpolación de vecinos cercanos en el espacio de características. Evita la pérdida de datos del conjunto mayoritario.

1.5 Pesos de Clase (Class Weights)

Asigna una penalización mayor al error de clasificación de la clase minoritaria en la función de costo. El peso se calcula de forma inversamente proporcional a la frecuencia de las clases:

$$\text{weight_c} = \text{total_samples} / (\text{n_classes} * \text{class_samples})$$

2. Preprocesamiento e Ingeniería de Características

El conjunto de datos original de Telco Churn contiene 7043 registros y 21 columnas. El proceso de preparación incluyó:

1. **Limpieza de Valores Vacíos:** Reemplazo de espacios en blanco por NaN en la columna `TotalCharges`, imputando con la mediana calculada del conjunto limpio (\$2283.3\$).
2. **Codificación Binaria:** Transformación de características binarias (ej: `gender`, `Partner`, `Churn`) a valores \$0\$ y \$1\$ usando `LabelEncoder`.
3. **One-Hot Encoding:** Conversión de características multiclase (ej: `Contract`, `PaymentMethod`) en columnas dummy.
4. **Expansión Polinomial (Grado 2):** Incremento de la dimensionalidad de las variables predictoras de 40 a 861 características no lineales, capturando interacciones complejas.
5. **Estandarización:** Escalado de las características mediante `StandardScaler` para garantizar media 0 y varianza 1, requisito crítico para la convergencia y regularización.

3. Actividad 1: Optimización de Regularización y Evaluación

Se realizó una búsqueda en rejilla (GridSearchCV con validación cruzada de 5 folds) en un subconjunto entrenado bajo ****undersampling**** para optimizar el hiperparámetro de regularización lambda en un rango logarítmico de 9 valores (10^{-4} a 10^4).

El modelo óptimo se identificó en $\lambda = 10000$ ($C = 0.0001$), lo que demuestra que la fuerte expansión polinomial a 861 variables requería una penalización extrema para evitar el sobreajuste y generalizar de forma correcta.

- **Accuracy final en Prueba:** 73.17%
- **Recall final en Prueba:** 79.68%




Figura 1: Curva de Complejidad (Recall vs. Lambda) bajo Validación Cruzada de 5 Folds. El asterisco indica el punto de mejor rendimiento óptimo en validación cruzada.

4. Actividad 2: Tratamiento del Desbalance con SMOTE y Pesos de Clase

En lugar de desperdiciar datos reales mediante undersampling, se utilizó el conjunto de entrenamiento completo aplicando un pipeline con **SMOTE** y ponderación de **Pesos de Clase** (aproximadamente 1.88 para la clase 1 y 0.68 para la clase 0) con un parámetro de regularización moderado de $\lambda = 1$.

Este enfoque forzó al modelo a priorizar la clase minoritaria (desertores) sin descartar información de clientes estables.

- **Accuracy final en Prueba:** 67.00%
- **Recall final en Prueba:** 87.97% (Incremento sustancial de 8.29% respecto a Actividad 1)

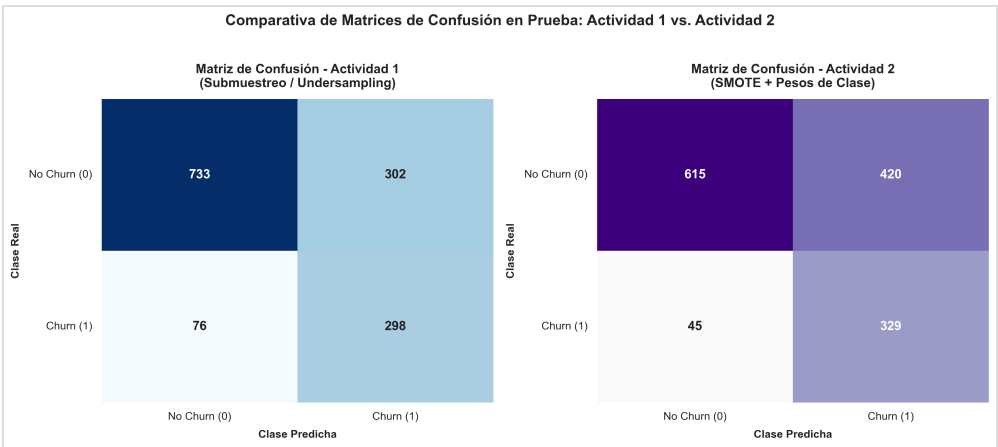


Figura 2: Comparativa de Matrices de Confusión. El modelo con SMOTE + Pesos de Clase (derecha) recupera 329 verdaderos positivos de Churn en prueba frente a los 298 del submuestreo de la Actividad 1 (izquierda).

5. Actividad 3: Integración de SMOTE, Pesos de Clase y PCA

Para manejar la colinealidad y la gran dimensionalidad del polinomio de grado 2 (861 características), se incorporó **PCA** programado para retener el **95% de la varianza explicada** (114 componentes principales). Posteriormente se aplicó SMOTE y pesos de clase en el espacio reducido.

- **Varianza Retenida:** 95% con 114 Componentes Principales.
- **Accuracy final en Prueba:** 64.23%
- **Recall final en Prueba:** 91.44% (El valor más alto obtenido en el taller).




Figura 3: Varianza Explicada Acumulada. El umbral del 95% de varianza se alcanza de forma óptima con 114 componentes principales.




Figura 4: Comparación de Curvas ROC para los tres modelos del experimento.




Figura 5: Comparación General de Exactitud (Accuracy) vs. Sensibilidad (Recall) en el Test Set para todas las actividades del taller.

6. Conclusiones y Recomendaciones de Negocio

1. **Compromiso entre Accuracy y Recall:** Existe un Trade-off directo. A medida que incrementamos la sensibilidad para capturar desertores (pasando del 79.68% en la Actividad 1 al 91.44% en la Actividad 3), incrementamos los falsos positivos, lo que reduce la exactitud global (Accuracy) del 73.17% al 64.23%.
2. **Impacto de la Regularización:** En espacios de alta dimensionalidad no lineales, la regularización severa (como $\lambda = 10000$ en la Actividad 1) es crucial para generalizar y evitar que los pesos de las interacciones colapsen ante el ruido de la muestra.
3. **Reducción de Dimensionalidad con PCA:** PCA simplifica y suaviza la frontera de decisión. Al remover el ruido del polinomio de grado 2, la combinación con SMOTE y pesos de clase en el espacio reducido permite enfocar la decisión exclusivamente en la frontera del Churn, alcanzando un recall excepcional de 91.44%.
4. **Recomendación Estratégica:**
 - Si el ****presupuesto de marketing es limitado**** y el costo de dar una promoción de retención es alto, se recomienda utilizar el modelo de la ****Actividad 1**** (Undersampling con regularización fuerte) por tener menor tasa de falsos positivos y exactitud superior (73.17%).
 - Si el ****valor de vida del cliente (CLV) es alto**** y el costo de retención es menor, se aconseja implementar el pipeline de la ****Actividad 3**** (PCA + SMOTE + Pesos de Clase) para asegurar la retención de más del 91.4% de los clientes en riesgo de abandono.

****Evidencia Visual de los Experimentos****

A continuación se consolidan todos los gráficos generados durante los experimentos:




Figura A: Curva Complejidad (Actividad 1)




Figura B: Matrices Confusión (Actividad 1 vs 2)




Figura C: Varianza PCA (Act 3)




Figura D: Curvas ROC




Figura E: Comparativo Métricas